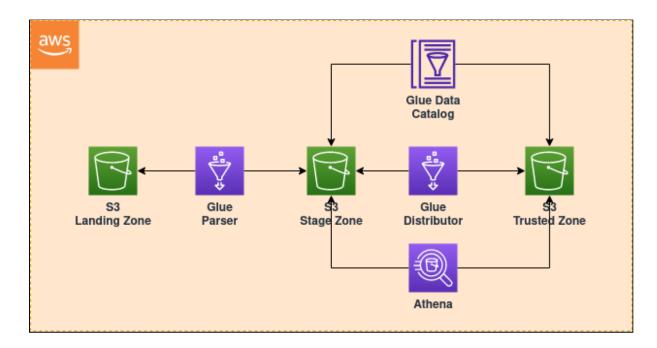
EVENT DISTRIBUTOR

SUMÁRIO

ARQUITETURA	3
PROVISIONAMENTO	4
ARQUIVOS E MÉTODOS	4
DEPLOY	6
EXECUÇÃO DO FLUXO	7
RESULTADOS	7
MELHORIAS	11

1. ARQUITETURA



As amostras de dados são disponibilizadas em um bucket chamado pismo-landing-zone. O upload pode ser feito manualmente ou utilizando AWS CLI. Dentro da landing zone há dois diretórios: pending e processed.

- pending: responsável por armazenar os arquivos a serem processados
- processed: reponsável por armazenar os arquivos já processados

Para o processamento dos dados, foi utilizado o serviço AWS Glue (PySpark). A primeira job, Parser, é responsável por ler da landing zone (pending), "parsear" os dados e salvá-los no bucket pismo-stage-zone/events. Os detalhes de processamento das jobs são explicados no capítulo 3 (Arquivos e Métodos) deste documento.

Assim que a job Parser é finalizada com sucesso, entra em execução a segunda etapa do processo, a job Distributor. Esta etapa possui a responsabilidade de ler os dados da stage zone e salvar no bucket pismo-trusted-zone, aplicando as regras e premissas do desafio.

O Glue Data Catalog foi utilizado para criar o catálogo dos dados salvos no S3 (stage e trusted). Foram utilizados crawlers para a criação das tabelas.

O Athena foi utilizado para explorar os dados processados via ANSI SQL.

2. PROVISIONAMENTO

Para prover a arquitetura da AWS usada no desafio foi utilizado o terraform, versão 0.14.9.

O arquivo terraform/main.tf contém os detalhes de cada recurso utilizado na infraestrutura (roles, policies, buckets e etc).

Para provisionar a infraestrutura é necessário ter o terraform instalado e as credenciais da AWS configuradas. Depois disso, basta executar: terraform apply.

3. ARQUIVOS E MÉTODOS

Para solucionar o desafio, foram criados dois arquivos principais utilizando a liguagem Python: **source/parser.py** e **source/distributor.py**. Este capítulo visa explicar os métodos presentes em cada arquivo e a sequência de execução de cada etapa.

Métodos Parser:

get pending files

Responsável por retornar um array contendo todos os caminhos de objetos (amostras) armazenados na landing zone pending/.

parser_to_s3

Recebe como parâmetro uma lista de caminhos de objetos armazenados no S3 (landing/pending). Para cada caminho de arquivo de amostra é realizado o parser do conteúdo (json) utilizando o método replace, depois disso, é criado o pandas dataframe tendo como conteúdo as linhas presentes no arquivo. Por fim, o arquivo é salvo no path: stage-zone/events no formato parquet.

move_pending_files_to_processed

Recebe como parâmetro uma lista de caminhos de objetos armazenados no S3 (landing-zone/pending). Para cada caminho de arquivo de amostra, os arquivos

são movidos para a pasta processed do bucket landing tendo como novo diretório a data atual de execução do processo, exemplo:

pismo-landing-zone/processed/date=2022-01-20/test.json Por fim, o diretório pending é zerado.

main

Método principal responsável por executar outros métodos na seguinte sequência:

- get_pending_files
- parser to s3
- move_pending_files_to_processed

Métodos Distributor:

define_event_type

Recebe como parâmetro um Dynamic Frame do Glue. É responsável por converter o parâmetro recebido em um Data Frame do spark e adicionar a coluna domain_event_type concatenando as colunas domain e event_type separando-as por "-". A concatenação é feita utilizando o método concat_ws. O médoto retorna o Data Frame.

define_date_columns

O método recebe como parâmetro um Data Frame e adiciona as colunas **year**, **month**, **day** extraídas do campo **timestamp**. O método retorna o Data Frame.

deduplicate

Recebe como parâmetro um Data Frame. Possui a responsabilidade de "deduplicar" os dados que se repetem com base nos campos event_id e timestamp. É utilizado SparkSQL para aplicar a "deduplicação". O método retorna um Data Frame.

save_to_trusted

O método recebe como parâmetro um Data Frame. É responsável por salvar os dados na trusted zone no formato parquet, separados pelas colunas domain_event_type, year, month e day.

erase_stage

Possui a responsabilidade de zerar a stage zone. Como resultado, o diretório **events/** fica vazio, aguardando o próximo processamento/carga.

main

O método tem a função de criar um Dynamic Frame com base na tabela externa events (criada via crawler) que pertence ao database pismo-stage-zone. Em sequência os seguintes métodos são acionados:

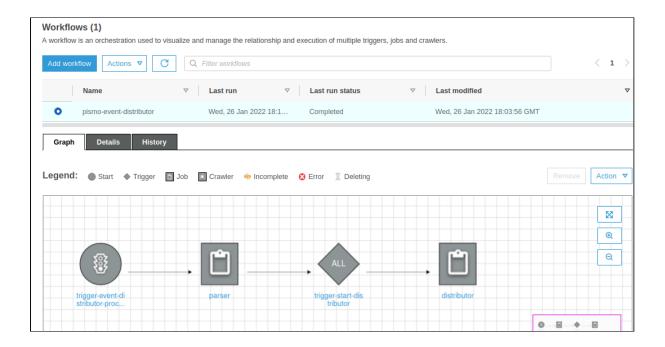
- define_event_type
- define_date_columns
- deduplicate
- save_to_trusted
- erase_stage

4. DEPLOY

Para realizar o deploy das jobs **source/parser.py** e **source/distributor.py** foi criado um arquivo chamado **deploy.sh**. O arquivo tem como objetivo copiar os scripts para o path: **s3://pismo-glue-scripts/** (bucket destinado a ser usado como fonte de código das jobs do Glue). A cópia é realizada via AWS CLI.

5. EXECUÇÃO DO FLUXO

Para executar o fluxo foi criado um Workflow do Glue:



O Workflow permite que as etapas (parser e distributor) sejam acionadas em sequência. Porém, a segunda parte só começa a rodar se a primeira finalizar com sucesso.

Os testes foram feitos acionando o fluxo manualmente, mas pode ser alterado para rodar em um horário específico ou a partir de um evento,

6. RESULTADOS

Depois que as jobs parser e distributor finalizam a execução, chega-se ao seguinte resultado:

pismo-trusted-zone/events:

Particionamento por domain event type, year, month e day:

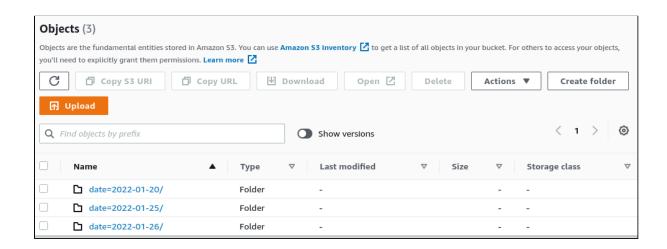


Exemplos de arquivos parquet:

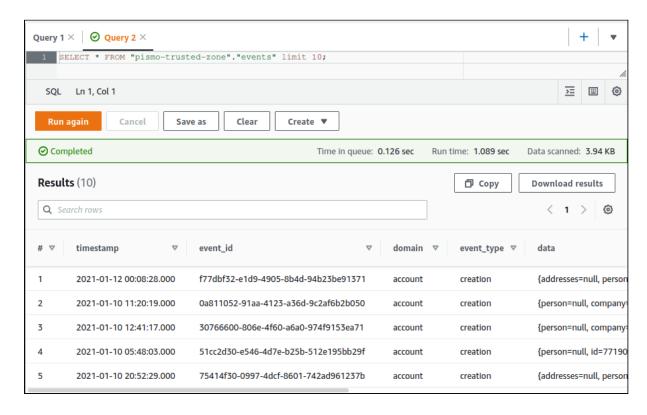


pismo-landing-zone/processed:

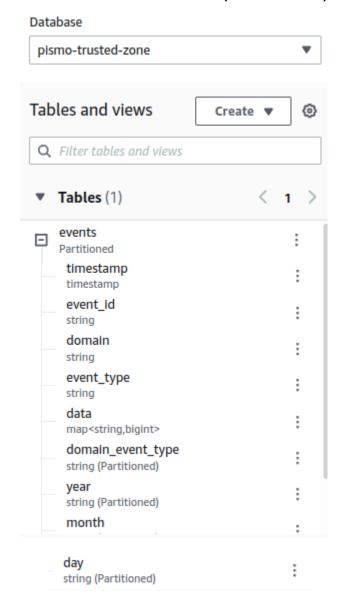
Dados já processados que poderão ser encontrados na landing zone, organizados por data, para um possível "reprocessamento" ou histórico.



Consumo via Athena (trusted zone):



Estrutura da tabela events (trusted zone):



Performance das jobs do Glue considerando o processamento de um arquivo de 2MB (5556 registros):

Parser:

Média de execução: 46 sec.

Distributor:

Média de execução: 1 min.

Observação: é possível que mesmo aumentando o tamanho da amostra ainda se mantenha o mesmo tempo de execução das jobs, pois foi testado com uma massa menor de dados e o tempo médio se manteve o mesmo.

7. MELHORIAS

Pontos importantes:

- Criar parametrização e organização de variáveis do terraform;
- Desenvolver testes unitários sobre as jobs do Glue;
- Criar rotina de deploy a partir de push no repositório e execução de testes;
- Criar arquivo de bibliotecas utilizadas nos scripts Python necessárias para rodar o projeto (Dependências);
- Monitoramento de execução do Workflow.
- Para o cenário onde é preciso tratar muitos arquivos, ao invés de excluir o arquivo das zonas de stage e landing/pending, abordar outra estratégia que minimize o custo com relação às requisições de DELETE.