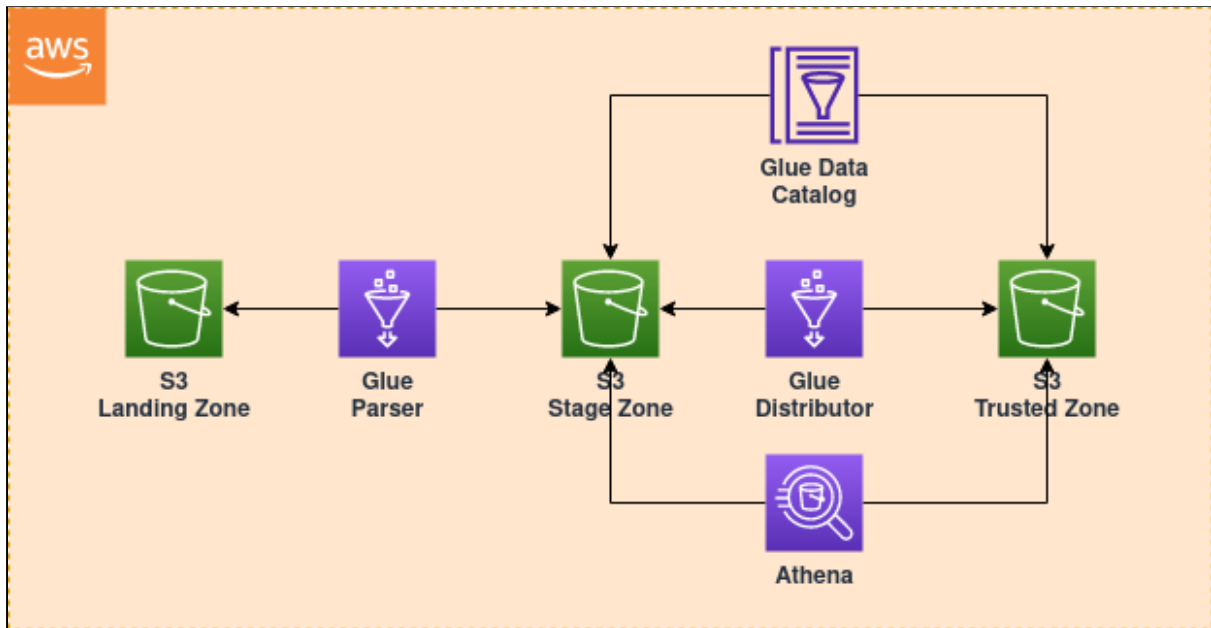


EVENT DISTRIBUTOR

SUMÁRIO

ARQUITETURA	3
PROVISIONAMENTO	4
ARQUIVOS E MÉTODOS	4
DEPLOY	6
EXECUÇÃO DO FLUXO	7
RESULTADOS	7
MELHORIAS	11

1. ARQUITETURA



As amostras de dados são disponibilizadas em um bucket chamado pismo-landing-zone. O upload pode ser feito manualmente ou utilizando AWS CLI. Dentro da landing zone há dois diretórios: pending e processed.

- pending: responsável por armazenar os arquivos a serem processados
- processed: responsável por armazenar os arquivos já processados

Para o processamento dos dados, foi utilizado o serviço AWS Glue (PySpark). A primeira job, Parser, é responsável por ler da landing zone (pending), “parsear” os dados e salvá-los no bucket pismo-stage-zone/events. Os detalhes de processamento das jobs são explicados no capítulo 3 (Arquivos e Métodos) deste documento.

Assim que a job Parser é finalizada com sucesso, entra em execução a segunda etapa do processo, a job Distributor. Esta etapa possui a responsabilidade de ler os dados da stage zone e salvar no bucket pismo-trusted-zone, aplicando as regras e premissas do desafio.

O Glue Data Catalog foi utilizado para criar o catálogo dos dados salvos no S3 (stage e trusted). Foram utilizados crawlers para a criação das tabelas.

O Athena foi utilizado para explorar os dados processados via ANSI SQL.

2. PROVISIONAMENTO

Para prover a arquitetura da AWS usada no desafio foi utilizado o terraform, versão 0.14.9.

O arquivo `terraform/main.tf` contém os detalhes de cada recurso utilizado na infraestrutura (roles, policieis, buckets e etc).

Para provisionar a infraestrutura é necessário ter o terraform instalado e as credenciais da AWS configuradas. Depois disso, basta executar: `terraform apply`.

3. ARQUIVOS E MÉTODOS

Para solucionar o desafio, foram criados dois arquivos principais utilizando a linguagem Python: `source/parser.py` e `source/distributor.py`. Este capítulo visa explicar os métodos presentes em cada arquivo e a sequência de execução de cada etapa.

Métodos Parser:

`get_pending_files`

Responsável por retornar um array contendo todos os caminhos de objetos (amostras) armazenados na landing zone pending/.

`parser_to_s3`

Recebe como parâmetro uma lista de caminhos de objetos armazenados no S3 (landing/pending). Para cada caminho de arquivo de amostra é realizado o parser do conteúdo (json) utilizando o método `replace`, depois disso, é criado o pandas dataframe tendo como conteúdo as linhas presentes no arquivo. Por fim, o arquivo é salvo no path: `stage-zone/events` no formato `parquet`.

`move_pending_files_to_processed`

Recebe como parâmetro uma lista de caminhos de objetos armazenados no S3 (landing-zone/pending). Para cada caminho de arquivo de amostra, os arquivos

são movidos para a pasta processed do bucket landing tendo como novo diretório a data atual de execução do processo, exemplo:

pismo-landing-zone/processed/date=2022-01-20/test.json

Por fim, o diretório pending é zerado.

main

Método principal responsável por executar outros métodos na seguinte sequência:

- get_pending_files
- parser_to_s3
- move_pending_files_to_processed

Métodos Distributor:

define_event_type

Recebe como parâmetro um Dynamic Frame do Glue. É responsável por converter o parâmetro recebido em um Data Frame do spark e adicionar a coluna **domain_event_type** concatenando as colunas **domain** e **event_type** separando-as por “-”. A concatenação é feita utilizando o método **concat_ws**. O método retorna o Data Frame.

define_date_columns

O método recebe como parâmetro um Data Frame e adiciona as colunas **year**, **month**, **day** extraídas do campo **timestamp**. O método retorna o Data Frame.

deduplicate

Recebe como parâmetro um Data Frame. Possui a responsabilidade de “deduplicar” os dados que se repetem com base nos campos **event_id** e **timestamp**. É utilizado SparkSQL para aplicar a “deduplicação”. O método retorna um Data Frame.

save_to_trusted

O método recebe como parâmetro um Data Frame. É responsável por salvar os dados na trusted zone no formato parquet, separados pelas colunas domain_event_type, year, month e day.

erase_stage

Possui a responsabilidade de zerar a stage zone. Como resultado, o diretório **events/** fica vazio, aguardando o próximo processamento/carga.

main

O método tem a função de criar um Dynamic Frame com base na tabela externa events (criada via crawler) que pertence ao database pismo-stage-zone. Em sequência os seguintes métodos são acionados:

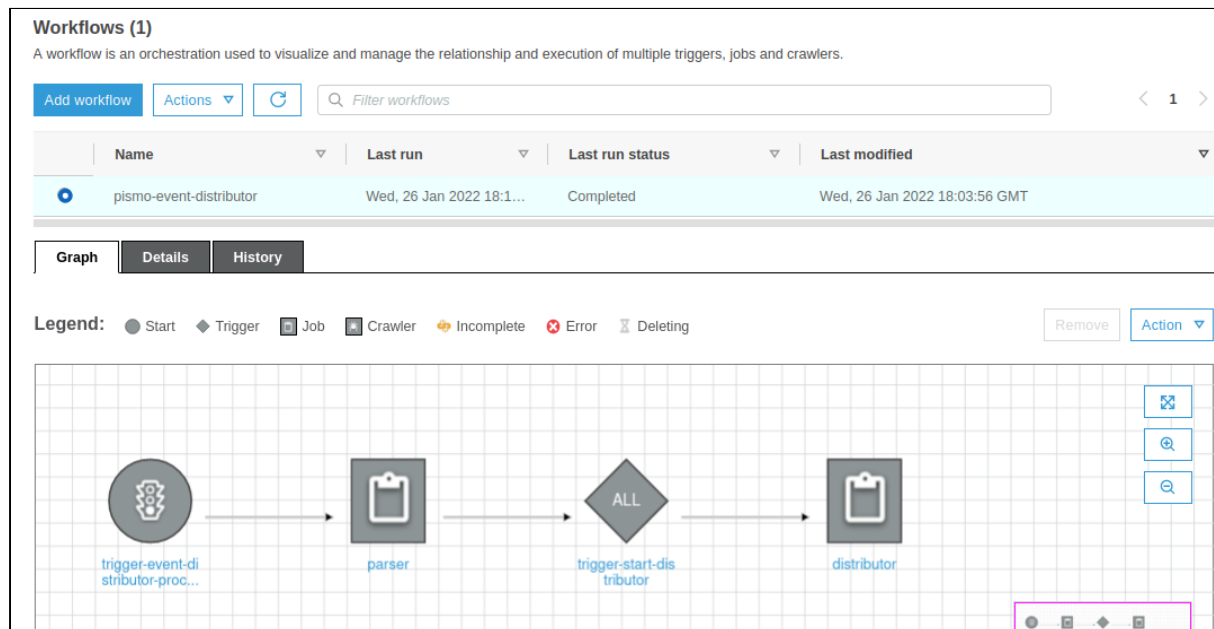
- define_event_type
- define_date_columns
- deduplicate
- save_to_trusted
- erase_stage

4. DEPLOY

Para realizar o deploy das jobs **source/parser.py** e **source/distributor.py** foi criado um arquivo chamado **deploy.sh**. O arquivo tem como objetivo copiar os scripts para o path: **s3://pismo-glue-scripts/** (bucket destinado a ser usado como fonte de código das jobs do Glue). A cópia é realizada via AWS CLI.

5. EXECUÇÃO DO FLUXO

Para executar o fluxo foi criado um Workflow do Glue:



O Workflow permite que as etapas (parser e distributor) sejam acionadas em sequência. Porém, a segunda parte só começa a rodar se a primeira finalizar com sucesso.

Os testes foram feitos acionando o fluxo manualmente, mas pode ser alterado para rodar em um horário específico ou a partir de um evento,

6. RESULTADOS

Depois que as jobs parser e distributor finalizam a execução, chega-se ao seguinte resultado:




pismo-trusted-zone/events:

Particionamento por domain_event_type, year, month e day:

Amazon S3 > pismo-trusted-zone > events/ > domain_event_type=account-creation/ > year=2021/ > month=1/ > day=10/

Amazon S3 > pismo-trusted-zone > events/ > domain_event_type=transaction-creation/ > year=2021/ > month=1/ > day=9/

Exemplos de arquivos parquet:







<input type="checkbox"/>	Name ▲	Type ▼	Last modified ▼	Size ▼	Storage class ▼
<input type="checkbox"/>	 part-00000-bf06e659-29f6-4c38-9d13-1646260bfcf9.c000.snappy.parquet	parquet	January 25, 2022, 16:17:58 (UTC-03:00)	2.2 KB	Standard
<input type="checkbox"/>	 part-00001-bf06e659-29f6-4c38-9d13-1646260bfcf9.c000.snappy.parquet	parquet	January 25, 2022, 16:17:58 (UTC-03:00)	2.2 KB	Standard
<input type="checkbox"/>	 part-00002-bf06e659-29f6-4c38-9d13-1646260bfcf9.c000.snappy.parquet	parquet	January 25, 2022, 16:17:58 (UTC-03:00)	2.2 KB	Standard


pismo-landing-zone/processed:



Dados já processados que poderão ser encontrados na landing zone, organizados por data, para um possível “reprocessamento” ou histórico.




Objects (3)

Objects are the fundamental entities stored in Amazon S3. You can use [Amazon S3 Inventory](#) to get a list of all objects in your bucket. For others to access your objects, you'll need to explicitly grant them permissions. [Learn more](#)

  Copy S3 URI  Copy URL  Download  Open  Delete **Actions ▼** **Create folder**

 Upload

 Show versions < 1 > 

<input type="checkbox"/>	Name ▲	Type ▼	Last modified ▼	Size ▼	Storage class ▼
<input type="checkbox"/>	 date=2022-01-20/	Folder	-	-	-
<input type="checkbox"/>	 date=2022-01-25/	Folder	-	-	-
<input type="checkbox"/>	 date=2022-01-26/	Folder	-	-	-

Consumo via Athena (trusted zone):

Query 1 × | ✔ Query 2 ×

1 | SELECT * FROM "pismo-trusted-zone"."events" limit 10;

SQL Ln 1, Col 1

Run again

Cancel

Save as

Clear

Create ▼

✔ Completed

Time in queue: 0.126 sec

Run time: 1.089 sec

Data scanned: 3.94 KB

Results (10)

Copy

Download results

Search rows

< 1 > ⚙

# ▼	timestamp ▼	event_id ▼	domain ▼	event_type ▼	data
1	2021-01-12 00:08:28.000	f77dbf32-e1d9-4905-8b4d-94b23be91371	account	creation	{addresses=null, person
2	2021-01-10 11:20:19.000	0a811052-91aa-4123-a36d-9c2af6b2b050	account	creation	{person=null, company
3	2021-01-10 12:41:17.000	30766600-806e-4f60-a6a0-974f9153ea71	account	creation	{person=null, company
4	2021-01-10 05:48:03.000	51cc2d30-e546-4d7e-b25b-512e195bb29f	account	creation	{person=null, id=77190
5	2021-01-10 20:52:29.000	75414f30-0997-4dcf-8601-742ad961237b	account	creation	{addresses=null, person

Estrutura de tabela (trusted zone):

Database

pismo-trusted-zone ▼

Tables and views Create ▼ ⚙️

🔍 *Filter tables and views*

▼ **Tables (1)** < 1 >

events	⋮
Partitioned	
timestamp	⋮
timestamp	
event_id	⋮
string	
domain	⋮
string	
event_type	⋮
string	
data	⋮
map<string,bigint>	
domain_event_type	⋮
string (Partitioned)	
year	⋮
string (Partitioned)	
month	⋮
day	⋮
string (Partitioned)	

Performance das jobs do Glue considerando o processamento de um arquivo de 2MB (5556 registros):

Parser:

Média de execução: 46 sec.

Distributor:

Média de execução: 1 min.

Observação: é possível que mesmo aumentando o tamanho da amostra ainda se mantenha o mesmo tempo de execução das jobs, pois foi testado com uma massa menor de dados e o tempo médio se manteve o mesmo.

7. MELHORIAS

Pontos importantes:

- Criar parametrização do terraform e organização de variáveis;
- Desenvolver testes unitários sobre as jobs do Glue;
- Criar rotina de deploy a partir de push no repositório e execução de testes;
- Criar arquivo de bibliotecas utilizadas nos scripts Python necessárias para rodar o projeto (Dependências);
- Monitoramento de execução do Workflow.